

# Modelo de Capacidad para la red comercial

Asignación óptima de 34.145 clientes Preferenciales a Gerentes de Inversión. Cuatro enfoques (analítico, greedy, MILP exacto y simulated annealing con MCMC) convergen al mismo óptimo. Este informe explica el problema, los datos, los caminos y, sobre todo, lo que se aprende cuando los métodos sofisticados *no* mejoran el resultado.

**40.76%**

Métrica oficial x/y  
= **techo teórico**

**40.8%**

Techo teórico  
predicho en EDA

**27.115**


Clientes asignados  
de 34.145 totales

**4 / 4**

Enfoques convergen  
al mismo óptimo

## El problema en una imagen

Bancolombia tiene una **red comercial jerárquica de tres niveles**. Hay que decidir cómo conectar el nivel intermedio (ejecutivos) con el nivel superior (gerentes), sabiendo que **los clientes están atados a su ejecutivo** y que cada gerente tiene un **tiempo limitado al año**.



### INSIGHT

Como **todos los clientes del ejecutivo** se asignan en bloque, la unidad de decisión **no es el cliente, es el ejecutivo**. Esto transforma el problema de 34.145 variables binarias en solo 392, lo que lo hace tratable con MILP exacto.

## La métrica oficial que tenemos que maximizar

$$\text{score} = \frac{x}{y} = \frac{\#A_{\text{asignados}} + \#B_{\text{asignados}}}{N_{\text{clientes totales}}}$$

El denominador es **fijo** (34.145 clientes). El numerador suma solo A y B asignados (*los C ya asignados no aportan*). Por eso el modelo prioriza  $A > B > C$  aunque la asignación es por ejecutivo.

La función realmente optimizada y su variable de decisión

La métrica oficial  $x/y$  **no es lineal** en las decisiones por ejecutivo (depende del conteo total de A y B asignados). Por eso el modelo no maximiza  $x/y$  directamente, sino una **función subrogada lineal** diseñada para alinearse con  $x/y$ :

$$\max_x \sum_{e \in E} \sum_{g \in G_e} V_e \cdot x_{e,g}$$

donde  $x_{e,g} \in \{0, 1\}$  es la **variable de decisión** (asignar o no al ejecutivo  $e$  al gerente  $g$ ), y  $V_e$  es el valor agregado del ejecutivo:

$$V_e = w_A \cdot n_e^A + w_B \cdot n_e^B + w_C \cdot n_e^C + \alpha \cdot n_e \cdot \bar{s}_e$$

**¿De dónde salen los pesos?** Se eligen tales que cada cliente A pese 10× más que un B y un B pese 100× más que un C:  $w_A = 1000$ ,  $w_B = 100$ ,  $w_C = 1$ . Con esa razón, asignar un solo ejecutivo con un cliente A siempre es preferible a asignar un ejecutivo con 9 clientes B (los cuales a su vez son preferibles a 99 C). Esto reproduce la prioridad del PDF (A>B>C).  $\alpha = 0,1$  es un peso pequeño para que el score promedio  $\bar{s}_e$  solo desempate.

Esta función se obtuvo por **análisis directo de la métrica**: se descompuso  $x/y$  en aportes por ejecutivo asumiendo que asignamos al ejecutivo completo, y se eligieron pesos que conservaran la prioridad relativa del PDF. La validación se hace observando que el MILP con esta función subrogada produce la misma solución que el SA con Hamiltoniano físico (ambos llegan a  $x/y = 0,4076$ ).

## Los datos disponibles

Recibimos **7 archivos CSV**. Cada uno aporta una pieza del problema. Los tamaños van desde 50 filas (gerentes) hasta 247 mil (oportunidades).



pcac\_mac\_gpi\_clientes

**34.145**

Población de clientes Preferencial con categoría A/B/C, score, zona y asignación actual.



pcac\_mac\_gpi\_ecas

**392**

Estructura de la red: relación gerente ↔ ejecutivo. *Llave crítica para el modelo.*



pcac\_oportunidades\_comer

**247.863**

Oportunidades comerciales por cliente y producto. Insumo para calcular tiempo demandado.



pcac\_mac\_gpi\_tenencia\_prod

**66.802**

Si el cliente ya tiene/usa cada producto. Define qué oportunidades requieren venta nueva.



pcac\_planta\_comercial2

**50**

Catálogo de Gerentes de Inversión con ciudad, región, banca y tipo.



pcac\_encuesta

**1.804**

Tiempos auto-reportados por (gerente, producto, etapa). Insumo para  $\tau_c$ .




pcac\_capacidad\_gerentes

**50**

Tiempo anual disponible  $T_g$  por gerente (75.930 min  $\approx$  1.265 horas).


### Distribución por categoría comercial

Distribución de clientes (n=34.145) · la pirámide A/B/C



# El hallazgo dominante: los huérfanos


Lo que parece un problema de optimización resulta ser un problema de calidad de datos. Antes de modelar, descubrimos que **el techo del problema está fijo**: no por capacidad, sino por integridad referencial.



## Impacto cuantificado en clientes

| GRUPO      | CLIENTES | %     | A     | B      | C      |
|------------|----------|-------|-------|--------|--------|
| Asignables | 27.115   | 79.4% | 3.916 | 10.000 | 13.199 |
| Huérfanos  | 7.030    | 20.6% | 1.579 | 2.727  | 2.724  |

## Los dos techos del problema



DIAGNÓSTICO

Aunque tuviéramos un modelo **perfecto**, la métrica jamás superará **40.8%**. Los 4.306 clientes A+B huérfanos son *estructuralmente* no asignables: sus ejecutivos no aparecen en la tabla ecas que define la jerarquía. **Mejorar el modelo no resuelve esto. Mejorar los datos sí.**

Validación de la conclusión

Una conclusión tan fuerte ("la métrica está acotada por integridad de datos") merece auditoría. Verifiqué tres aspectos: **tipos de dato**, **filtros de universo** y **composición por segmento**. La conclusión se sostiene, con un matiz importante.



Llaves consistentes

cod\_ejec\_bco es string en ambas tablas (clientes y ecas). Sin pérdida de precisión en enteros de 19 dígitos. Los IDs son textualmente idénticos cuando coinciden.



Universo bien definido

Los **34.145 clientes** tienen marca\_mac\_inv no nula (A/B/C 100%). El **99,94%** tiene estado\_gte\_inv = ACTIVO. El universo está limpio.



Matiz por segmento

De los 7.030 huérfanos: **4.446 son Preferencial/Plus** (scope estricto del MAC GPI). Los **2.584 restantes** son PYMES, Personal, Empresarial. *Su ejecutivo es de otra banca.*

Composición por segmento de los 7.030 clientes huérfanos

| SEGMENTO DEL CLIENTE | A   | B     | C     | TOTAL | LECTURA                                  |
|----------------------|-----|-------|-------|-------|------------------------------------------|
| PREFERENCIAL         | 433 | 1.181 | 1.610 | 3.224 | Scope natural; ejec aún sin GPI          |
| PLUS                 | 257 | 443   | 522   | 1.222 | Banca premium, mismo caso                |
| PYMES                | 458 | 353   | 129   | 940   | Ejec. de banca PYME, no de Inversión     |
| PERSONAL             | 106 | 347   | 327   | 780   | Persona natural sin gerente de inversión |
| NEGOCIOS & INDEP.    | 67  | 121   | 74    | 262   | Ejec. de banca corporativa pequeña       |
| EMPRESARIAL          | 129 | 164   | 6     | 299   | Ejec. de banca empresarial               |
| Otros                | 3   | 10    | 10    | 23    | Corporativa, gobierno, internacional     |

LECTURA

El hallazgo es **real**: hay 633 ejecutivos cuyos clientes están marcados para el MAC de Inversión, pero ellos pertenecen a otras bancas (PYME, Personal, Empresarial) sin Gerente de Inversión asociado. **No es un error de merge** ni un problema de tipos: las llaves coinciden cuando deben coincidir. Es un hecho operativo: el *marcado del cliente* en marca\_mac\_inv va por delante de la *reasignación del ejecutivo* a la jerarquía de inversión, lo cual la prueba prohíbe explícitamente con la regla "los clientes no pueden moverse ni reasignarse a otros ejecutivos".

# De lo simple a lo sofisticado

Implementamos cuatro enfoques con complejidad creciente, no para "asegurar" el resultado, sino para **triangular y diagnosticar**. Si los cuatro convergen → la solución es robusta. Si difieren → hay decisión real.

NIVEL 1 · SIMPLE

● Analítico (regla)

Ordena ejecutivos por  $A \rightarrow B \rightarrow C \rightarrow \text{score}$ , asigna al primer gerente compatible con capacidad.

| TIEMPO | RESULTADO |
|--------|-----------|
| 0.06s  | 0.4076    |

Cómo se llega: una sola pasada por la lista ordenada, primer gerente compatible que aún tenga capacidad libre se queda con el ejecutivo. Sin búsqueda, sin retroceso.

NIVEL 2 · HEURÍSTICA

● Greedy densidad  $v/t$

Prioriza ejecutivos por **valor/tiempo** ( $\rho = v_e / t_e$ ), best-fit por capacidad.

| TIEMPO | RESULTADO |
|--------|-----------|
| 0.06s  | 0.4076    |

Cómo se llega: ordena por  $\rho = v_e / t_e$  descendente y elige el gerente compatible con la menor capacidad libre suficiente (best-fit), reduciendo fragmentación.

NIVEL 3 · EXACTO

● MILP (PuLP + CBC)

Programación entera mixta. **Garantía de óptimo global** por construcción.

| TIEMPO | ESTADO  |
|--------|---------|
| 0.49s  | Optimal |

Cómo se llega: el solver CBC explora un árbol de configuraciones binarias usando ramificación y poda; descarta ramas cuya cota superior ya está debajo del mejor encontrado.

NIVEL 4 · FÍSICO

● Simulated Annealing

Cadena MCMC sobre Hamiltoniano de Ising. Aporta **diagnósticos físicos**.

| PASOS  | RESULTADO |
|--------|-----------|
| 80.000 | 0.4076    |

Cómo se llega: cadena de Markov con regla de Metropolis: propone movimientos aleatorios (flip o swap) y los acepta con probabilidad  $e^{(-\Delta H/T)}$ . Al enfriar  $T$ , converge al estado fundamental.

► Explorar las 4 metodologías de forma interactiva ►

Simulaciones paso a paso: árbol de branch & bound, cooling curve, best-fit en vivo

## El pipeline ejecutado

1

Carga

7 CSVs en data/raw/

2

Feature engineering

$\tau_c$  y  $t_e$  por ejecutivo

3

4



#### 4 modelos

Analytical, greedy, MILP, SA

#### Validación


5 reglas duras del PDF

5

#### Export

resultado\_prueba.csv

## Comparación visual de los 4 enfoques



#### LECTURA

Los cuatro enfoques producen **exactamente la misma asignación**. No es coincidencia: es evidencia empírica de que el problema **no tiene mínimos locales malos**. El paisaje energético es trivial → el modelo más simple basta para producción.

# El problema **es** un Ising spin glass

No es analogía pedagógica. Es **equivalencia matemática exacta**: podemos formular el problema en lenguaje del banco o en lenguaje de física, y cada formulación produce los mismos resultados óptimos. Lo interesante es lo que se gana al ver el problema desde cada lado.

## Versión 1: el problema en lenguaje del banco

Para cada par (ejecutivo  $e$ , gerente  $g$ ), el banco decide  $x_{e,g} \in \{0, 1\}$ : asignar al ejecutivo a ese gerente (1) o no (0). Maximiza el **valor comercial total**:

$$\max \sum_{e,g} \underbrace{V_e}_{\text{valor del ejecutivo}} \cdot x_{e,g}$$

donde  $V_e = 1000 \cdot n_e^A + 100 \cdot n_e^B + 1 \cdot n_e^C + 0,1 \cdot n_e \bar{s}_e$  pondera los clientes A/B/C que el ejecutivo trae consigo, según prioridad oficial.

Sujeto a tres restricciones de negocio:

- **1. Único gerente:**  $\sum_g x_{e,g} \leq 1$  para todo ejecutivo (no se puede dividir cartera).
- **2. Capacidad anual:**  $\sum_e t_e \cdot x_{e,g} \leq T_g$  para todo gerente (no se sobrepasa el tiempo disponible).
- **3. Misma zona:**  $x_{e,g} = 0$  si  $\text{zona}(e) \neq \text{zona}(g)$  (no cruzar regiones).

## Versión 2: el mismo problema como Ising spin glass

Cambiamos  $x_{e,g}$  por un **spin de Ising**  $\sigma_{e,g} \in \{0, 1\}$ , y reformulamos el negocio como minimización de la **energía**  $H(\sigma)$ :

$$\min H(\sigma) = \underbrace{- \sum_{e,g} v_e \sigma_{e,g}}_{\text{campo externo (tira a 1)}} + \underbrace{\sum_g \lambda_g \left( \sum_e t_e \sigma_{e,g} - T_g \right)_+^2}_{\text{muro de capacidad}}$$

**Equivalencia exacta:** el estado fundamental  $\arg \min H$  con  $\lambda_g \rightarrow \infty$  es *idéntico* a la solución óptima del problema del banco. Las restricciones duras (zona, único gerente) son reglas que filtran configuraciones permitidas, no van en  $H$ .

## Equivalencia: misma matemática, dos lenguajes

| CONCEPTO DEL BANCO         | CONCEPTO FÍSICO                   | SIGNIFICADO DEL MAPEO                                          |
|----------------------------|-----------------------------------|----------------------------------------------------------------|
| Decisión binaria $x_{e,g}$ | Spin $\sigma_{e,g} \in \{0, 1\}$  | Cada par ejecutivo-gerente es una variable binaria del sistema |
| Valor del ejecutivo $V_e$  | Campo externo $h_{e,g} = -v_e$    | Cuanto más valioso, más fuerte tira al spin hacia 1 (asignar)  |
| Tiempo demandado $t_e$     | Masa del spin (en restricción)    | Lo que el ejecutivo "pesa" en la capacidad del gerente         |
| Capacidad anual $T_g$      | Profundidad del pozo de potencial | Hasta cuánta masa cabe antes de que el sistema rechace más     |

| CONCEPTO DEL BANCO               | CONCEPTO FÍSICO                          | SIGNIFICADO DEL MAPEO                                                  |
|----------------------------------|------------------------------------------|------------------------------------------------------------------------|
| Sobrepaso de capacidad           | Resorte unilateral cuadrático            | Penalización suave si overshoot pequeño, brutal si grande              |
| Restricción de zona              | Espacio de configuraciones reducido      | Vínculos prohibidos; los pares cross-zona ni siquiera existen          |
| Único gerente por ejecutivo      | Exclusión tipo Pauli                     | El ejecutivo solo puede ocupar un "estado de asignación"               |
| Solución óptima del MILP         | Estado fundamental ( $T \rightarrow 0$ ) | Configuración de mínima energía es la asignación de máximo valor       |
| Pesos $w_A, w_B, w_C$            | Magnitud del campo externo               | Tunable: cambia la "preferencia" del sistema sin alterar las reglas    |
| Heterogeneidad de $t_e$ por ejec | Glassiness (vidrioso, no cristalino)     | Sistema desordenado por construcción; no admite simplificación trivial |

#### INSIGHT

Cuando los dos lenguajes describen la *misma* matemática, podemos elegir el método según el objetivo. Para encontrar la solución óptima exacta: MILP. Para entender cómo de robusta es esa solución ante cambios o cómo escalaría con datos más grandes: la termodinámica del sistema.

#### ¿Qué es un campo externo?

En física, un campo externo (ej. magnético) actúa sobre cada spin individualmente, intentando alinearlos. Aquí,  $V_e$  es el campo: **cuanto más valor trae el ejecutivo, más fuerte tira hacia "asignar"**. La capacidad es el contrapeso que impide que todos se asignen.

#### ¿Por qué un resorte unilateral?

El término  $(\sum t_e \sigma_{e,g} - T_g)_+^2$  es cero si la capacidad NO se sobrepasa, y crece **cuadráticamente** si sí. Esto modela bien la realidad operativa: estar al 105% es aceptable; estar al 200% es desastroso.

## Estado de spines (configuración $\sigma$ )



↑  $\sigma_{eg} = 1$  (asignado)    ↓  $\sigma_{eg} = 0$  (no asignado)

*El estado fundamental = asignación óptima*

### Tres diagnósticos físicos: qué gana el banco, qué gana el físico

Los siguientes tres diagnósticos solo emergen del enfoque físico (MILP no los produce). Cada uno se explica en doble lenguaje: **qué le dice al físico** y **qué le dice al banco**.

#### 1. Curva de enfriamiento $\langle H \rangle(T)$

**Qué es:** energía promedio del sistema en función de la temperatura, observada al lo largo de la simulación.

 **Para el físico:** trayectoria del sistema desde alta temperatura (estado caótico, exploración) hacia  $T \rightarrow 0$  (estado fundamental). Plateau final = convergencia. Saltos abruptos = transiciones de fase: el sistema reorganizó masivamente su estructura.

 **Para el banco:** ¿qué tan rápido y suave el modelo encuentra la asignación óptima cuando arranca desde una configuración aleatoria? Si baja monótona y se aplana, el modelo está bien afinado. Si tiene saltos, hay puntos donde "reordenar" ejecutivos cambia mucho el valor total: zonas de inestabilidad operativa.

#### 2. Calor específico $C(T) = \frac{\langle H^2 \rangle - \langle H \rangle^2}{T^2}$

**Qué es:** varianza de la energía sobre  $T^2$ . Mide la sensibilidad del sistema a cambios de temperatura.

 **Para el físico:** un *pico afilado* a  $T_c$  marca una transición de fase.  $C$  residual alto a  $T \rightarrow 0$  indica *frustración*: el sistema no puede satisfacer todas las restricciones simultáneamente. Sin pico = sin transición, problema fácil.

 **Para el banco:** ¿hay un “umbral” en los pesos a partir del cual el modelo empieza a comportarse de forma diferente? Si SÍ, los parámetros del modelo son *frágiles* cerca de ese umbral; si calibras los pesos cerca, pequeños cambios producen reasignaciones masivas. Si NO, el modelo es robusto, el negocio puede confiar.

**3. Susceptibilidad**  $\chi(T) = \frac{\langle M^2 \rangle - \langle M \rangle^2}{T}$

**Qué es:** varianza del número total de ejecutivos asignados  $M$  sobre  $T$ . Mide cómo responde la “magnetización total” ante el campo externo.

 **Para el físico:** equivalente a la susceptibilidad magnética. Una  $\chi$  alta significa que el sistema responde fuertemente al campo, una  $\chi$  baja significa rigidez ante perturbaciones.

 **Para el banco:** si subo  $w_A$  de 1000 a 1500, ¿cuántos ejecutivos cambian de gerente? Susceptibilidad *baja*  $\Rightarrow$  la asignación es estable, no hace falta calibrar finamente los pesos. Susceptibilidad *alta*  $\Rightarrow$  la elección de pesos importa mucho, y ahí el negocio debe definir explícitamente sus prioridades.


#### LECTURA

**Para nuestro problema concreto:**  $C$  residual bajo,  $\chi$  residual baja, curva de enfriamiento sin saltos. Los tres diagnósticos coinciden: **el problema no tiene frustración estructural y la solución es robusta**. Esto es coherente con que los cuatro métodos de optimización converjan al mismo valor 0.4076.

## ¿Cuándo conviene cada método?

| MÉTODO              | LO QUE EL BANCO GANA                 | LO QUE EL FÍSICO GANA                               | CUÁNDO ELEGIRLO                                |
|---------------------|--------------------------------------|-----------------------------------------------------|------------------------------------------------|
| Analítico (regla)   | Solución explicable a no-técnicos    | Aproximación de campo medio “a mano”                | Demos rápidas, baseline, comunicación a comité |
| Greedy densidad     | Tiempo de cómputo < 1 s, escalable   | Aproximación de Bethe / mean-field                  | Producción diaria, pipelines automatizados     |
| MILP exacto         | Garantía formal de optimalidad       | Diagonalización exacta del Hamiltoniano             | Cierre mensual, reportes regulatorios          |
| Simulated Annealing | Diagnóstico de robustez ante cambios | Termodinámica completa: $C$ , $\chi$ , transiciones | Auditoría del modelo, análisis de sensibilidad |

# Lo que el modelo entrega




## Estructura del archivo resultado\_prueba.csv

Esquema y tipos consistentes con la plantilla del PDF. **27.115 filas**, una por cada cliente asignado. Los clientes no asignados se omiten del archivo (regla del enunciado).

| COLUMNA          | TIPO                | DESCRIPCIÓN                                 |
|------------------|---------------------|---------------------------------------------|
| num_doc_cli      | string (19 dígitos) | Documento del cliente asignado              |
| cod_tipo_doc_cli | integer             | Tipo de documento (1, 2, ...)               |
| cod_ejec_bco     | string (19 dígitos) | Ejecutivo del cliente                       |
| num_doc_gte_inv  | string (19 dígitos) | Documento del Gerente de Inversión asignado |
| cod_gte_inv      | string (19 dígitos) | Código del Gerente de Inversión asignado    |

## Validaciones que pasa el resultado



# La solución completa, paso a paso

El archivo resultado\_prueba.csv se genera de forma reproducible con un solo comando. A continuación, los cuatro módulos clave que lo producen, con el código real del repositorio.

## Pipeline en 5 pasos

src/modelo\_capacidad/run\_all.py

ORQUESTADOR

```
# 1. Carga las 7 tablas (loader con dtype=string para IDs de 19 dígitos)
clientes, ecas, capacidad, encuesta, oport, tenencia, planta = load_all()

# 2. Calcula tiempo demandado por cliente ( $\tau_c$ ) y por ejecutivo ( $t_e$ )
tau = calcular_tau_cliente(oport, tenencia, encuesta)
df_ejec = construir_df_ejecutivos(clientes, tau, ecas)
df_ger = construir_df_gerentes(capacidad, ecas)

# 3. Resuelve con MILP exacto (CBC) - garantía de óptimo global
res = asignar_milp(df_ejec, df_ger, time_limit=300, gap_rel=0.001)

# 4. Valida las 5 reglas duras del PDF y exporta el CSV
resultado, metricas = validar_y_exportar(
    res.asignaciones, df_ejec, df_ger, clientes, planta,
    out_path="resultado_prueba.csv"
)
print(f"x/y = {metricas['metrica_x_y']:.4f}") # 0.4076
```

## Feature engineering: cálculo de $\tau_c$

El tiempo demandado por cliente sale de cruzar oportunidades, tenencia y la encuesta de tiempos. Tres casos:

src/modelo\_capacidad/features/tiempo\_demanda.py

FEATURE ENGINEERING

```
def calcular_tau_cliente(oportunidades, tenencia, encuesta):
    # Mediana de minutos por (producto, etapa) - robusta a outliers
    tabla = construir_tabla_tiempos(encuesta)

    df = oportunidades.merge(tenencia, on=["num_doc_cli", "cod_producto"])
    df["producto_norm"] = df["producto"].replace(PRODUCTO_MAP)

    # Vectorizado con np.where: 3 casos según tenencia/uso
    no_tiene = df["tenencia"].fillna(0) == 0
    tiene_no_usa = (df["tenencia"] == 1) & (df["usa_producto"].fillna(0) == 0)

    minutos = np.where(no_tiene, t_venta_nueva, # Caso 1: venta nueva
                       np.where(tiene_no_usa, t_postventa, # Caso 2: activación
                                0.0)) # Caso 3: tiene y usa

    df["minutos"] = minutos
    return df.groupby("num_doc_cli")["minutos"].sum().reset_index(name="tau")
```

## Modelo MILP exacto

Programación entera con PuLP/CBC. Optimal en 0.49 s para 370 ejecutivos × 49 gerentes con filtro de zona.

src/modelo\_capacidad/models/milp.py

OPTIMIZACIÓN EXACTA

```
def asignar_milp(df_ejec, df_ger, time_limit=300, gap_rel=0.001):
    # Pares válidos (ejecutivo, gerente) con misma zona
    pares = [(e, g) for e in df_ejec["cod_ejec_bco"]
              for g in df_ger["cod_gte_inv"]
              if zona[e] == zona[g]]

    model = pl.LpProblem("asignacion", pl.LpMaximize)
    x = pl.LpVariable.dicts("x", pares, cat=pl.LpBinary)

    # Objetivo: max  $\sum v_e \cdot x_{eg}$ 
    model += pl.lpSum(valor[e] * x[(e, g)] for (e, g) in pares)

    # R1: a lo más un gerente por ejecutivo
    for e in df_ejec["cod_ejec_bco"]:
        model += pl.lpSum(x[p] for p in pares if p[0] == e) <= 1

    # R2: capacidad anual por gerente
    for g in df_ger["cod_gte_inv"]:
        model += pl.lpSum(tiempo[e] * x[(e, g)]
                          for (e, gg) in pares if gg == g) <= cap[g]

    model.solve(pl.PULP_CBC_CMD(timeLimit=time_limit, gapRel=gap_rel))
    return [(e, g) for (e, g) in pares if x[(e, g)].value() > 0.5]
```

## Validación y exportación del CSV

Antes de escribir el archivo se verifican las 5 reglas duras del PDF. Si alguna falla, el pipeline detiene la publicación.

src/modelo\_capacidad/utils/validators.py

VALIDACIÓN + EXPORT

```
def validar_y_exportar(asignaciones_ejec, df_ejec, df_ger, clientes, planta, out_path):
    # Las 5 validaciones duras del PDF
    validar_unico_gerente(asignaciones_ejec)      # 1 ejec → 1 gerente
    validar_misma_zona(asignaciones_ejec, df_ejec, df_ger)
    uso = validar_capacidad(asignaciones_ejec, df_ejec, df_ger)

    # Expande (ejec, gerente) → filas a nivel cliente (regla todo-o-nada)
    resultado = expandir_a_clientes(asignaciones_ejec, clientes, planta)

    # Calcula la métrica oficial x/y
    metricas = metrica_oficial(resultado, clientes)

    # Exporta con esquema EXACTO de la plantilla del PDF
    resultado[["num_doc_cli", "cod_tipo_doc_cli", "cod_ejec_bco",
               "num_doc_gte_inv", "cod_gte_inv"]].to_csv(out_path,
                                                         index=False,
                                                         encoding="utf-8")

    return resultado, metricas    # 27,115 filas, x/y = 0.4076
```

### REPRODUCIBILIDAD

El pipeline completo se ejecuta de extremo a extremo en una sola línea:

```
uv run python -m modelo_capacidad.run_all
```

Tiempo total ~3 segundos. Genera artefactos intermedios en data/processed/ y el archivo final resultado\_prueba.csv en la raíz del repo. Los **19 tests pytest** validan que cada función respeta su contrato.



# Entregables del proyecto

Cobertura de los cuatro entregables del PDF + extras: pipeline reproducible, tests automáticos y subagentes especializados.

| # | ENTREGABLE PDF                   | ARCHIVO / UBICACIÓN                               | ESTADO |
|---|----------------------------------|---------------------------------------------------|--------|
| 1 | Documento explicativo            | docs/documento_final.md + este HTML               | ✓      |
| 2 | Archivo de asignación            | resultado_prueba.csv (27.115 filas)               | ✓      |
| 3 | Códigos documentados             | src/modelo_capacidad/ + tests/                    | ✓      |
| 4 | Bosquejo arquitectura            | Sección anterior + docs/arquitectura.md           | ✓      |
| + | Variables adicionales (opcional) | docs/variables_adicionales.md + sección siguiente | ✓      |

# Variables adicionales propuestas

Recomendaciones organizadas por origen y costo. Detalle completo en docs/variables\_adicionales.md. Notación: ● bajo, ● medio, ● alto.


| ORIGEN                     | VARIABLES CLAVE                                                                                                                                                     | POR QUÉ                                                                          | COSTO                                                                      |
|----------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------|----------------------------------------------------------------------------|
| Internas (data warehouse)  | Volumen y monto transaccional, recencia, ticket promedio, churn score, tasa histórica de respuesta a campañas, tasa de cierre del ejecutivo, antigüedad del cliente | Refina $v_e$ y $\tau_c$ ; permite priorizar retención sobre venta cuando aplica  | <span style="color: green;">●</span>                                       |
| Telemetría CRM             | Tiempo real medido por actividad (reemplaza la encuesta auto-reportada)                                                                                             | Reduce el error de medición de $\tau_c$ de >50% a <10%                           | <span style="color: green;">●</span>                                       |
| Externas · buró            | Score DataCrédito / TransUnion, endeudamiento, reportes negativos                                                                                                   | Mejor identificación de A reales (clientes solventes con capacidad de inversión) | <span style="color: orange;">●</span>                                      |
| Externas · sociodemografía | Estrato (DANE), CIU enriquecido (Asobancaria), composición del hogar                                                                                                | Segmentación adicional para el score upstream                                    | <span style="color: orange;">●</span>                                      |
| Externas · macro           | Tasa USD/COP, IBR, DTF, IPC (APIs Banco de la República y DANE)                                                                                                     | Ajustar pesos según ciclo económico                                              | <span style="color: green;">●</span>                                       |
| Scraping / proveedores     | LinkedIn Sales Navigator, RUES (Cámara de Comercio), Catastro, EMIS                                                                                                 | Patrimonio visible y actividad empresarial; sólo si los anteriores plateauan     | <span style="color: orange;">●</span> / <span style="color: red;">●</span> |

INSIGHT

**Antes de buscar más datos afuera, hay que aprovechar bien los que ya hay adentro.** Reconciliar los 633 ejecutivos huérfanos en la tabla ecas sube el techo de la métrica de 40,8% a 53,4% (+12,6 puntos), *sin tocar el algoritmo ni traer datos nuevos*. Esa es la inversión con mayor ROI inmediato.

# Arquitectura del sistema


Bosquejo conceptual que permite servir los resultados del modelo a páginas web, app móvil, CRM y servicios externos. La idea es separar el **cómputo (batch)** del **consumo (consultas instantáneas)**: el modelo corre periódicamente, escribe sus resultados versionados en una tabla, y una API REST expone esos resultados con baja latencia.



## Endpoints clave de la API

| ENDPOINT                                 | PARA QUÉ                                                           | CONSUMIDOR TÍPICO          |
|------------------------------------------|--------------------------------------------------------------------|----------------------------|
| GET /asignacion/cliente/{num_doc_cli}    | Saber a qué gerente y ejecutivo está asignado un cliente           | CRM, app móvil del gerente |
| GET /asignacion/gerente/{cod_gte_inv}    | Cartera completa de un gerente + carga de tiempo acumulada         | Dashboard del gerente      |
| GET /asignacion/ejecutivo/{cod_ejec_bco} | Reporte del ejecutivo: clientes, mix A/B/C, gerente al que reporta | Reporte interno            |
| GET /metricas/run/{run_id}               | KPIs de una corrida: x/y, %A, %B, utilización media                | Comité, área analítica     |
| GET /metricas/historico                  | Evolución mensual de los KPIs para detectar drift                  | Power BI ejecutivo         |

La arquitectura incluye además una **capa de agentes IA sobre MCP (Model Context Protocol)**: un servidor MCP en Lambda expone los endpoints como herramientas, y cualquier asistente IA (Claude en Bedrock, copilots, agentes propios) las consume sin integraciones ad-hoc.



## Componentes AWS y decisiones técnicas



### AWS Lambda · job de modelado

Container image desde ECR con uv;  
corre en < 1 s, sin servidores.



### EventBridge + Step Functions

Trigger mensual y orquestación  
extract → modelo → validators  
con reintentos.



### Amazon Redshift Serverless

Tabla de asignaciones particionada  
por run\_id; histórico replicado a S3.



### API Gateway + Lambda (FastAPI)

REST con WAF, autenticación Cognito  
y FastAPI sobre Mangum.



### Cognito + IAM + KMS

OAuth2/SAML federado, least-  
privilege por servicio y cifrado en  
reposito.



### CloudWatch + X-Ray + SNS

Logs, traceo distribuido y alertas si  
métricas hacen drift > 15% MoM.



### ECR + CodePipeline

Versiona imágenes con SemVer; build,  
test y deploy automáticos al hacer  
push.



### QuickSight

Dashboards ejecutivos conectados  
directo a Redshift, sin SQL para el  
usuario.



### Servidor MCP · Lambda

Expone endpoints como tools MCP  
para cualquier asistente IA (Claude,  
copilots).



### Asistente del gerente

Amazon Lex + Chime SDK en  
Teams/Slack/móvil que consulta el  
MCP.



### Explainer · Bedrock Agents

Genera la razón en lenguaje natural de  
cada asignación (cumplimiento).



### Copilot what-if · SageMaker

Notebook + tool MCP para  
simulaciones de escenarios sin  
escribir código.



#### Watchdog agent

EventBridge → Lambda → SNS con alerta proactiva si hay drift.

#### Gobernanza de agentes

Roles IAM por agente, logs cifrados y política de no-fabricación.

#### INSIGHT

El modelo en sí es lo más barato del sistema: corre en menos de 1 segundo. Lo que cuesta dinero y tiempo de implementación es la **infraestructura de servicio**: API, cache, autenticación, observabilidad y gobernanza. Por eso el bosquejo se concentra en separar las capas y dejar el cómputo desacoplado: cualquier mejora futura del modelo (cambiar pesos, agregar SA, escalar el problema) se publica reemplazando el job batch sin tocar la API ni los consumidores.

# Conclusiones

1

## La métrica obtenida coincide con el techo teórico

40.76%  $\approx$  40.8% predicho. Esto valida que el modelo es óptimo y que el techo no es artefacto del algoritmo.

2

## Convergen porque no compiten por capacidad

Sobre-oferta (ratio 0.70). El MILP no encuentra ganancia porque no hay decisión real que tomar.

4

## El verdadero entregable es el diagnóstico

El CSV se podría producir con regla determinista en 0.06 s. Lo valioso es el techo cuantificado *antes* de optimizar.

5

## Frontera tenue entre optimización y datos

Aceptar que es proyecto de gobernanza, no de algoritmos, demuestra madurez analítica.

5

## El análogo físico vale más allá de este problema

Aunque innecesaria para este caso concreto, pueden existir muchos problemas del banco donde los análogos físicos (spin glass, mean-field, transiciones de fase) permitan entender y explicar mejor el negocio.

7

## La métrica oficial puede ser injusta

Reportar 40.76% sin contexto omite que el techo del problema está en 40.8%. Por eso este informe empieza por el techo.

## Oportunidades de mejora

Oport.

### Reconciliar huérfanos en ecas

Recupera los 633 ejecutivos que están en clientes pero no en ecas. Sin tocar algoritmo.

↑ Métrica: 40.8% → 53.4% (+12.6 puntos)

Oport.

### Tabla maestra de productos

Vocabulario unificado entre oportunidades y encuesta. Hoy mitigado con mapeo manual.

↑  $\tau_c$  con error reducido del 50% al 10%

Oport.

### Telemetría real de actividad

Reemplazar la encuesta auto-reportada con tiempos medidos directamente del CRM.

↑ Validez del modelo en producción

Oport.

### Variables internas adicionales

Histórico de campañas, tasa de respuesta, ticket promedio, churn, todas desde el data warehouse.

↑ Mejor priorización dentro de A/B

Oport.

### Variables externas (DataCrédito, DANE)

Buró, estrato, sector económico. APIs ya existentes. Solo si los pasos previos plateauean.

## Bancolombia

Modelo de Capacidad · Asignación óptima cliente / gerente

Pipeline reproducible: `uv run python -m modelo_capacidad.run_all`

 [github.com/jdrincone/modelo-capacidad](https://github.com/jdrincone/modelo-capacidad)

 Versión publicada: [modelo-capacidad.netlify.app](https://modelo-capacidad.netlify.app)

Generado el 8 de mayo de 2026 · [jdrincon@gmail.com](mailto:jdrincon@gmail.com)