

Modelo de Capacidad para la red comercial

Asignación óptima de 34.145 clientes Preferenciales a Gerentes de Inversión. Cuatro enfoques (analítico, greedy, MILP exacto y simulated annealing con MCMC) convergen al mismo óptimo. Este informe explica el problema, los datos, los caminos y, sobre todo, lo que se aprende cuando los métodos sofisticados *no* mejoran el resultado.

40.76%

Métrica oficial x/y
= **techo teórico**

40.8%

Techo teórico
predicho en EDA

27.115


Clientes asignados
de 34.145 totales

4 / 4

Enfoques convergen
al mismo óptimo

El problema en una imagen

Bancolombia tiene una **red comercial jerárquica de tres niveles**. Hay que decidir cómo conectar el nivel intermedio (ejecutivos) con el nivel superior (gerentes), sabiendo que **los clientes están atados a su ejecutivo** y que cada gerente tiene un **tiempo limitado al año**.



INSIGHT

Como **todos los clientes del ejecutivo** se asignan en bloque, la unidad de decisión **no es el cliente, es el ejecutivo**. Esto transforma el problema de 34.145 variables binarias en solo 392, lo que lo hace tratable con MILP exacto.

La métrica oficial que tenemos que maximizar

$$\text{score} = \frac{x}{y} = \frac{\#A_{\text{asignados}} + \#B_{\text{asignados}}}{N_{\text{clientes totales}}}$$

El denominador es **fijo** (34.145 clientes). El numerador suma solo A y B asignados (*los C ya asignados no aportan*). Por eso el modelo prioriza $A > B > C$ aunque la asignación es por ejecutivo.

La función realmente optimizada y su variable de decisión

La métrica oficial x/y **no es lineal** en las decisiones por ejecutivo (depende del conteo total de A y B asignados). Por eso el modelo no maximiza x/y directamente, sino una **función subrogada lineal** diseñada para alinearse con x/y :

$$\max_x \sum_{e \in E} \sum_{g \in G_e} V_e \cdot x_{e,g}$$

donde $x_{e,g} \in \{0, 1\}$ es la **variable de decisión** (asignar o no al ejecutivo e al gerente g), y V_e es el valor agregado del ejecutivo:

$$V_e = w_A \cdot n_e^A + w_B \cdot n_e^B + w_C \cdot n_e^C + \alpha \cdot n_e \cdot \bar{s}_e$$

¿De dónde salen los pesos? Se eligen tales que cada cliente A pese 10× más que un B y un B pese 100× más que un C: $w_A = 1000$, $w_B = 100$, $w_C = 1$. Con esa razón, asignar un solo ejecutivo con un cliente A siempre es preferible a asignar un ejecutivo con 9 clientes B (los cuales a su vez son preferibles a 99 C). Esto reproduce la prioridad del PDF (A>B>C). $\alpha = 0,1$ es un peso pequeño para que el score promedio $\bar{s}_e$ solo desempate.

Esta función se obtuvo por **análisis directo de la métrica**: se descompuso x/y en aportes por ejecutivo asumiendo que asignamos al ejecutivo completo, y se eligieron pesos que conservaran la prioridad relativa del PDF. La validación se hace observando que el MILP con esta función subrogada produce la misma solución que el SA con Hamiltoniano físico (ambos llegan a $x/y = 0,4076$).

Los datos disponibles

Recibimos **7 archivos CSV**. Cada uno aporta una pieza del problema. Los tamaños van desde 50 filas (gerentes) hasta 247 mil (oportunidades).



pcac_mac_gpi_clientes

34.145

Población de clientes Preferencial con categoría A/B/C, score, zona y asignación actual.



pcac_mac_gpi_ecas

392

Estructura de la red: relación gerente ↔ ejecutivo. *Llave crítica para el modelo.*



pcac_oportunidades_comer

247.863

Oportunidades comerciales por cliente y producto. Insumo para calcular tiempo demandado.



pcac_mac_gpi_tenencia_prod

66.802

Si el cliente ya tiene/usa cada producto. Define qué oportunidades requieren venta nueva.



pcac_planta_comercial2

50

Catálogo de Gerentes de Inversión con ciudad, región, banca y tipo.



pcac_encuesta

1.804

Tiempos auto-reportados por (gerente, producto, etapa). Insumo para τ_c .




pcac_capacidad_gerentes

50

Tiempo anual disponible T_g por gerente (75.930 min $\approx$ 1.265 horas).


Distribución por categoría comercial

Distribución de clientes (n=34.145) · la pirámide A/B/C



El hallazgo dominante: los huérfanos


Lo que parece un problema de optimización resulta ser un problema de calidad de datos. Antes de modelar, descubrimos que **el techo del problema está fijo**: no por capacidad, sino por integridad referencial.



Impacto cuantificado en clientes

GRUPO	CLIENTES	%	A	B	C
Asignables	27.115	79.4%	3.916	10.000	13.199
Huérfanos	7.030	20.6%	1.579	2.727	2.724

Los dos techos del problema



DIAGNÓSTICO

Aunque tuviéramos un modelo **perfecto**, la métrica jamás superará **40.8%**. Los 4.306 clientes A+B huérfanos son *estructuralmente* no asignables: sus ejecutivos no aparecen en la tabla ecas que define la jerarquía. **Mejorar el modelo no resuelve esto. Mejorar los datos sí.**

Validación de la conclusión

Una conclusión tan fuerte ("la métrica está acotada por integridad de datos") merece auditoría. Verifiqué tres aspectos: **tipos de dato**, **filtros de universo** y **composición por segmento**. La conclusión se sostiene, con un matiz importante.



Llaves consistentes

cod_ejec_bco es string en ambas tablas (clientes y ecas). Sin pérdida de precisión en enteros de 19 dígitos. Los IDs son textualmente idénticos cuando coinciden.



Universo bien definido

Los **34.145 clientes** tienen marca_mac_inv no nula (A/B/C 100%). El **99,94%** tiene estado_gte_inv = ACTIVO. El universo está limpio.



Matiz por segmento

De los 7.030 huérfanos: **4.446 son Preferencial/Plus** (scope estricto del MAC GPI). Los **2.584 restantes** son PYMES, Personal, Empresarial. *Su ejecutivo es de otra banca.*

Composición por segmento de los 7.030 clientes huérfanos

SEGMENTO DEL CLIENTE	A	B	C	TOTAL	LECTURA
PREFERENCIAL	433	1.181	1.610	3.224	Scope natural; ejec aún sin GPI
PLUS	257	443	522	1.222	Banca premium, mismo caso
PYMES	458	353	129	940	Ejec. de banca PYME, no de Inversión
PERSONAL	106	347	327	780	Persona natural sin gerente de inversión
NEGOCIOS & INDEP.	67	121	74	262	Ejec. de banca corporativa pequeña
EMPRESARIAL	129	164	6	299	Ejec. de banca empresarial
Otros	3	10	10	23	Corporativa, gobierno, internacional

LECTURA

El hallazgo es **real**: hay 633 ejecutivos cuyos clientes están marcados para el MAC de Inversión, pero ellos pertenecen a otras bancas (PYME, Personal, Empresarial) sin Gerente de Inversión asociado. **No es un error de merge** ni un problema de tipos: las llaves coinciden cuando deben coincidir. Es un hecho operativo: el *marcado del cliente* en marca_mac_inv va por delante de la *reasignación del ejecutivo* a la jerarquía de inversión, lo cual la prueba prohíbe explícitamente con la regla "los clientes no pueden moverse ni reasignarse a otros ejecutivos".

De lo simple a lo sofisticado

Implementamos cuatro enfoques con complejidad creciente, no para "asegurar" el resultado, sino para **triangular y diagnosticar**. Si los cuatro convergen → la solución es robusta. Si difieren → hay decisión real.

NIVEL 1 · SIMPLE

● Analítico (regla)

Ordena ejecutivos por A→B→C→score, asigna al primer gerente compatible con capacidad.

TIEMPO	RESULTADO
0.06s	0.4076

Cómo se llega: una sola pasada por la lista ordenada, primer gerente compatible que aún tenga capacidad libre se queda con el ejecutivo. Sin búsqueda, sin retroceso.

NIVEL 2 · HEURÍSTICA

● Greedy densidad v/t

Prioriza ejecutivos por **valor/tiempo** ($\rho = v_e / t_e$), best-fit por capacidad.

TIEMPO	RESULTADO
0.06s	0.4076

Cómo se llega: ordena por $\rho = v_e / t_e$ descendente y elige el gerente compatible con la menor capacidad libre suficiente (best-fit), reduciendo fragmentación.

NIVEL 3 · EXACTO

● MILP (PuLP + CBC)

Programación entera mixta. **Garantía de óptimo global** por construcción.

TIEMPO	ESTADO
0.49s	Optimal

Cómo se llega: el solver CBC explora un árbol de configuraciones binarias usando ramificación y poda; descarta ramas cuya cota superior ya está debajo del mejor encontrado.

NIVEL 4 · FÍSICO

● Simulated Annealing

Cadena MCMC sobre Hamiltoniano de Ising. Aporta **diagnósticos físicos**.

PASOS	RESULTADO
80.000	0.4076

Cómo se llega: cadena de Markov con regla de Metropolis: propone movimientos aleatorios (flip o swap) y los acepta con probabilidad $e^{(-\Delta H/T)}$. Al enfriar T , converge al estado fundamental.

El pipeline ejecutado

1

Carga

7 CSVs en data/raw/

2

Feature engineering

τ_c y t_e por ejecutivo

3

4 modelos

Analytical, greedy, MILP, SA

4


Validación

5 reglas duras del PDF

5

Export

resultado_prueba.csv

Comparación visual de los 4 enfoques**LECTURA**

Los cuatro enfoques producen **exactamente la misma asignación**. No es coincidencia: es evidencia empírica de que el problema **no tiene mínimos locales malos**. El paisaje energético es trivial → el modelo más simple basta para producción.

El problema **es** un Ising spin glass

No es analogía pedagógica. Es **equivalencia matemática exacta**: podemos formular el problema en lenguaje del banco o en lenguaje de física, y cada formulación produce los mismos resultados óptimos. Lo interesante es lo que se gana al ver el problema desde cada lado.

Versión 1: el problema en lenguaje del banco

Para cada par (ejecutivo e , gerente g), el banco decide $x_{e,g} \in \{0, 1\}$: asignar al ejecutivo a ese gerente (1) o no (0). Maximiza el **valor comercial total**:

$$\max \sum_{e,g} \underbrace{V_e}_{\text{valor del ejecutivo}} \cdot x_{e,g}$$

donde $V_e = 1000 \cdot n_e^A + 100 \cdot n_e^B + 1 \cdot n_e^C + 0,1 \cdot n_e \bar{s}_e$ pondera los clientes A/B/C que el ejecutivo trae consigo, según prioridad oficial.

Sujeto a tres restricciones de negocio:

- **1. Único gerente:** $\sum_g x_{e,g} \leq 1$ para todo ejecutivo (no se puede dividir cartera).
- **2. Capacidad anual:** $\sum_e t_e \cdot x_{e,g} \leq T_g$ para todo gerente (no se sobrepasa el tiempo disponible).
- **3. Misma zona:** $x_{e,g} = 0$ si $\text{zona}(e) \neq \text{zona}(g)$ (no cruzar regiones).

Versión 2: el mismo problema como Ising spin glass

Cambiamos $x_{e,g}$ por un **spin de Ising** $\sigma_{e,g} \in \{0, 1\}$, y reformulamos el negocio como minimización de la **energía** $H(\sigma)$:

$$\min H(\sigma) = \underbrace{- \sum_{e,g} v_e \sigma_{e,g}}_{\text{campo externo (tira a 1)}} + \underbrace{\sum_g \lambda_g \left(\sum_e t_e \sigma_{e,g} - T_g \right)_+^2}_{\text{muro de capacidad}}$$

Equivalencia exacta: el estado fundamental $\arg \min H$ con $\lambda_g \rightarrow \infty$ es *idéntico* a la solución óptima del problema del banco. Las restricciones duras (zona, único gerente) son reglas que filtran configuraciones permitidas, no van en H .

Equivalencia: misma matemática, dos lenguajes

CONCEPTO DEL BANCO	CONCEPTO FÍSICO	SIGNIFICADO DEL MAPEO
Decisión binaria $x_{e,g}$	Spin $\sigma_{e,g} \in \{0, 1\}$	Cada par ejecutivo-gerente es una variable binaria del sistema
Valor del ejecutivo V_e	Campo externo $h_{e,g} = -v_e$	Cuanto más valioso, más fuerte tira al spin hacia 1 (asignar)
Tiempo demandado t_e	Masa del spin (en restricción)	Lo que el ejecutivo "pesa" en la capacidad del gerente
Capacidad anual T_g	Profundidad del pozo de potencial	Hasta cuánta masa cabe antes de que el sistema rechace más

CONCEPTO DEL BANCO	CONCEPTO FÍSICO	SIGNIFICADO DEL MAPEO
Sobrepaso de capacidad	Resorte unilateral cuadrático	Penalización suave si overshoot pequeño, brutal si grande
Restricción de zona	Espacio de configuraciones reducido	Vínculos prohibidos; los pares cross-zona ni siquiera existen
Único gerente por ejecutivo	Exclusión tipo Pauli	El ejecutivo solo puede ocupar un "estado de asignación"
Solución óptima del MILP	Estado fundamental ($T \rightarrow 0$)	Configuración de mínima energía es la asignación de máximo valor
Pesos w_A, w_B, w_C	Magnitud del campo externo	Tunable: cambia la "preferencia" del sistema sin alterar las reglas
Heterogeneidad de t_e por ejec	Glassiness (vidrioso, no cristalino)	Sistema desordenado por construcción; no admite simplificación trivial

INSIGHT

Cuando los dos lenguajes describen la *misma* matemática, podemos elegir el método según el objetivo. Para encontrar la solución óptima exacta: MILP. Para entender cómo de robusta es esa solución ante cambios o cómo escalaría con datos más grandes: la termodinámica del sistema.

¿Qué es un campo externo?

En física, un campo externo (ej. magnético) actúa sobre cada spin individualmente, intentando alinearlos. Aquí, V_e es el campo: **cuanto más valor trae el ejecutivo, más fuerte tira hacia "asignar"**. La capacidad es el contrapeso que impide que todos se asignen.

¿Por qué un resorte unilateral?

El término $(\sum t_e \sigma_{e,g} - T_g)_+^2$ es cero si la capacidad NO se sobrepasa, y crece **cuadráticamente** si sí. Esto modela bien la realidad operativa: estar al 105% es aceptable; estar al 200% es desastroso.

Estado de spines (configuración σ)



↑ $\sigma_{eg} = 1$ (asignado) ↓ $\sigma_{eg} = 0$ (no asignado)

El estado fundamental = asignación óptima

Tres diagnósticos físicos: qué gana el banco, qué gana el físico

Los siguientes tres diagnósticos solo emergen del enfoque físico (MILP no los produce). Cada uno se explica en doble lenguaje: **qué le dice al físico** y **qué le dice al banco**.

1. Curva de enfriamiento $\langle H \rangle(T)$

Qué es: energía promedio del sistema en función de la temperatura, observada al lo largo de la simulación.

 **Para el físico:** trayectoria del sistema desde alta temperatura (estado caótico, exploración) hacia $T \rightarrow 0$ (estado fundamental). Plateau final = convergencia. Saltos abruptos = transiciones de fase: el sistema reorganizó masivamente su estructura.

 **Para el banco:** ¿qué tan rápido y suave el modelo encuentra la asignación óptima cuando arranca desde una configuración aleatoria? Si baja monótona y se aplana, el modelo está bien afinado. Si tiene saltos, hay puntos donde "reordenar" ejecutivos cambia mucho el valor total: zonas de inestabilidad operativa.

2. Calor específico $C(T) = \frac{\langle H^2 \rangle - \langle H \rangle^2}{T^2}$

Qué es: varianza de la energía sobre T^2 . Mide la sensibilidad del sistema a cambios de temperatura.

 **Para el físico:** un *pico afilado* a T_c marca una transición de fase. C residual alto a $T \rightarrow 0$ indica *frustración*: el sistema no puede satisfacer todas las restricciones simultáneamente. Sin pico = sin transición, problema fácil.

 **Para el banco:** ¿hay un “umbral” en los pesos a partir del cual el modelo empieza a comportarse de forma diferente? Si SÍ, los parámetros del modelo son *frágiles* cerca de ese umbral; si calibras los pesos cerca, pequeños cambios producen reasignaciones masivas. Si NO, el modelo es robusto, el negocio puede confiar.

3. Susceptibilidad $\chi(T) = \frac{\langle M^2 \rangle - \langle M \rangle^2}{T}$

Qué es: varianza del número total de ejecutivos asignados M sobre T . Mide cómo responde la “magnetización total” ante el campo externo.

 **Para el físico:** equivalente a la susceptibilidad magnética. Una χ alta significa que el sistema responde fuertemente al campo, una χ baja significa rigidez ante perturbaciones.

 **Para el banco:** si subo w_A de 1000 a 1500, ¿cuántos ejecutivos cambian de gerente? Susceptibilidad *baja* $\Rightarrow$ la asignación es estable, no hace falta calibrar finamente los pesos. Susceptibilidad *alta* $\Rightarrow$ la elección de pesos importa mucho, y ahí el negocio debe definir explícitamente sus prioridades.


LECTURA

Para nuestro problema concreto: C residual bajo, χ residual baja, curva de enfriamiento sin saltos. Los tres diagnósticos coinciden: **el problema no tiene frustración estructural y la solución es robusta**. Esto es coherente con que los cuatro métodos de optimización converjan al mismo valor 0.4076.

¿Cuándo conviene cada método?

MÉTODO	LO QUE EL BANCO GANA	LO QUE EL FÍSICO GANA	CUÁNDO ELEGIRLO
Analítico (regla)	Solución explicable a no-técnicos	Aproximación de campo medio “a mano”	Demos rápidas, baseline, comunicación a comité
Greedy densidad	Tiempo de cómputo < 1 s, escalable	Aproximación de Bethe / mean-field	Producción diaria, pipelines automatizados
MILP exacto	Garantía formal de optimalidad	Diagonalización exacta del Hamiltoniano	Cierre mensual, reportes regulatorios
Simulated Annealing	Diagnóstico de robustez ante cambios	Termodinámica completa: C , χ , transiciones	Auditoría del modelo, análisis de sensibilidad

Lo que el modelo entrega




Estructura del archivo resultado_prueba.csv

Esquema y tipos consistentes con la plantilla del PDF. **27.115 filas**, una por cada cliente asignado. Los clientes no asignados se omiten del archivo (regla del enunciado).

COLUMNA	TIPO	DESCRIPCIÓN
num_doc_cli	string (19 dígitos)	Documento del cliente asignado
cod_tipo_doc_cli	integer	Tipo de documento (1, 2, ...)
cod_ejec_bco	string (19 dígitos)	Ejecutivo del cliente
num_doc_gte_inv	string (19 dígitos)	Documento del Gerente de Inversión asignado
cod_gte_inv	string (19 dígitos)	Código del Gerente de Inversión asignado

Validaciones que pasa el resultado



La solución completa, paso a paso

El archivo resultado_prueba.csv se genera de forma reproducible con un solo comando. A continuación, los cuatro módulos clave que lo producen, con el código real del repositorio.

Pipeline en 5 pasos

src/modelo_capacidad/run_all.py

ORQUESTADOR

```
# 1. Carga las 7 tablas (loader con dtype=string para IDs de 19 dígitos)
clientes, ecas, capacidad, encuesta, oport, tenencia, planta = load_all()

# 2. Calcula tiempo demandado por cliente ( $\tau_c$ ) y por ejecutivo ( $t_e$ )
tau = calcular_tau_cliente(oport, tenencia, encuesta)
df_ejec = construir_df_ejecutivos(clientes, tau, ecas)
df_ger = construir_df_gerentes(capacidad, ecas)

# 3. Resuelve con MILP exacto (CBC) - garantía de óptimo global
res = asignar_milp(df_ejec, df_ger, time_limit=300, gap_rel=0.001)

# 4. Valida las 5 reglas duras del PDF y exporta el CSV
resultado, metricas = validar_y_exportar(
    res.asignaciones, df_ejec, df_ger, clientes, planta,
    out_path="resultado_prueba.csv"
)
print(f"x/y = {metricas['metrica_x_y']:.4f}") # 0.4076
```

Feature engineering: cálculo de τ_c

El tiempo demandado por cliente sale de cruzar oportunidades, tenencia y la encuesta de tiempos. Tres casos:

src/modelo_capacidad/features/tiempo_demanda.py

FEATURE ENGINEERING

```
def calcular_tau_cliente(oportunidades, tenencia, encuesta):
    # Mediana de minutos por (producto, etapa) - robusta a outliers
    tabla = construir_tabla_tiempos(encuesta)

    df = oportunidades.merge(tenencia, on=["num_doc_cli", "cod_producto"])
    df["producto_norm"] = df["producto"].replace(PRODUCTO_MAP)

    # Vectorizado con np.where: 3 casos según tenencia/uso
    no_tiene = df["tenencia"].fillna(0) == 0
    tiene_no_usa = (df["tenencia"] == 1) & (df["usa_producto"].fillna(0) == 0)

    minutos = np.where(no_tiene, t_venta_nueva, # Caso 1: venta nueva
                      np.where(tiene_no_usa, t_postventa, # Caso 2: activación
                               0.0)) # Caso 3: tiene y usa

    df["minutos"] = minutos
    return df.groupby("num_doc_cli")["minutos"].sum().reset_index(name="tau")
```

Modelo MILP exacto

Programación entera con PuLP/CBC. Optimal en 0.49 s para 370 ejecutivos × 49 gerentes con filtro de zona.

src/modelo_capacidad/models/milp.py

OPTIMIZACIÓN EXACTA

```
def asignar_milp(df_ejec, df_ger, time_limit=300, gap_rel=0.001):
    # Pares válidos (ejecutivo, gerente) con misma zona
    pares = [(e, g) for e in df_ejec["cod_ejec_bco"]
              for g in df_ger["cod_gte_inv"]
              if zona[e] == zona[g]]

    model = pl.LpProblem("asignacion", pl.LpMaximize)
    x = pl.LpVariable.dicts("x", pares, cat=pl.LpBinary)

    # Objetivo: max  $\sum v_e \cdot x_{eg}$ 
    model += pl.lpSum(valor[e] * x[(e, g)] for (e, g) in pares)

    # R1: a lo más un gerente por ejecutivo
    for e in df_ejec["cod_ejec_bco"]:
        model += pl.lpSum(x[p] for p in pares if p[0] == e) <= 1

    # R2: capacidad anual por gerente
    for g in df_ger["cod_gte_inv"]:
        model += pl.lpSum(tiempo[e] * x[(e, g)]
                          for (e, gg) in pares if gg == g) <= cap[g]

    model.solve(pl.PULP_CBC_CMD(timeLimit=time_limit, gapRel=gap_rel))
    return [(e, g) for (e, g) in pares if x[(e, g)].value() > 0.5]
```

Validación y exportación del CSV

Antes de escribir el archivo se verifican las 5 reglas duras del PDF. Si alguna falla, el pipeline detiene la publicación.

src/modelo_capacidad/utils/validators.py

VALIDACIÓN + EXPORT

```
def validar_y_exportar(asignaciones_ejec, df_ejec, df_ger, clientes, planta, out_path):
    # Las 5 validaciones duras del PDF
    validar_unico_gerente(asignaciones_ejec)      # 1 ejec → 1 gerente
    validar_misma_zona(asignaciones_ejec, df_ejec, df_ger)
    uso = validar_capacidad(asignaciones_ejec, df_ejec, df_ger)

    # Expande (ejec, gerente) → filas a nivel cliente (regla todo-o-nada)
    resultado = expandir_a_clientes(asignaciones_ejec, clientes, planta)

    # Calcula la métrica oficial x/y
    metricas = metrica_oficial(resultado, clientes)

    # Exporta con esquema EXACTO de la plantilla del PDF
    resultado[["num_doc_cli", "cod_tipo_doc_cli", "cod_ejec_bco",
               "num_doc_gte_inv", "cod_gte_inv"]].to_csv(out_path,
                                                         index=False,
                                                         encoding="utf-8")

    return resultado, metricas    # 27,115 filas, x/y = 0.4076
```

REPRODUCIBILIDAD

El pipeline completo se ejecuta de extremo a extremo en una sola línea:

```
uv run python -m modelo_capacidad.run_all
```

Tiempo total ~3 segundos. Genera artefactos intermedios en data/processed/ y el archivo final resultado_prueba.csv en la raíz del repo. Los **19 tests pytest** validan que cada función respeta su contrato.

Entregables del proyecto

Cobertura de los cuatro entregables del PDF + extras: pipeline reproducible, tests automáticos y subagentes especializados.

#	ENTREGABLE PDF	ARCHIVO / UBICACIÓN	ESTADO
1	Documento explicativo	docs/documento_final.md + este HTML	✓
2	Archivo de asignación	resultado_prueba.csv (27.115 filas)	✓
3	Códigos documentados	src/modelo_capacidad/ + tests/	✓
4	Bosquejo arquitectura	Sección anterior + docs/arquitectura.md	✓
+	Variables adicionales (opcional)	docs/variables_adicionales.md + sección siguiente	✓

Variables adicionales propuestas

Recomendaciones organizadas por origen y costo. Detalle completo en docs/variables_adicionales.md. Notación: ● bajo, ● medio, ● alto.


ORIGEN	VARIABLES CLAVE	POR QUÉ	COSTO
Internas (data warehouse)	Volumen y monto transaccional, recencia, ticket promedio, churn score, tasa histórica de respuesta a campañas, tasa de cierre del ejecutivo, antigüedad del cliente	Refina v_e y τ_c ; permite priorizar retención sobre venta cuando aplica	●
Telemetría CRM	Tiempo real medido por actividad (reemplaza la encuesta auto-reportada)	Reduce el error de medición de τ_c de >50% a <10%	●
Externas · buró	Score DataCrédito / TransUnion, endeudamiento, reportes negativos	Mejor identificación de A reales (clientes solventes con capacidad de inversión)	●
Externas · sociodemografía	Estrato (DANE), CIU enriquecido (Asobancaria), composición del hogar	Segmentación adicional para el score upstream	●
Externas · macro	Tasa USD/COP, IBR, DTF, IPC (APIs Banco de la República y DANE)	Ajustar pesos según ciclo económico	●
Scraping / proveedores	LinkedIn Sales Navigator, RUES (Cámara de Comercio), Catastro, EMIS	Patrimonio visible y actividad empresarial; sólo si los anteriores plateauan	● / ●

INSIGHT

Antes de buscar más datos afuera, hay que aprovechar bien los que ya hay adentro. Reconciliar los 633 ejecutivos huérfanos en la tabla ecas sube el techo de la métrica de 40,8% a 53,4% (+12,6 puntos), *sin tocar el algoritmo ni traer datos nuevos*. Esa es la inversión con mayor ROI inmediato.

Arquitectura del sistema


Bosquejo conceptual que permite servir los resultados del modelo a páginas web, app móvil, CRM y servicios externos. La idea es separar el **cómputo (batch)** del **consumo (consultas instantáneas)**: el modelo corre periódicamente, escribe sus resultados versionados en una tabla, y una API REST expone esos resultados con baja latencia.



Endpoints clave de la API

ENDPOINT	PARA QUÉ	CONSUMIDOR TÍPICO
GET /asignacion/cliente/{num_doc_cli}	Saber a qué gerente y ejecutivo está asignado un cliente	CRM, app móvil del gerente
GET /asignacion/gerente/{cod_gte_inv}	Cartera completa de un gerente + carga de tiempo acumulada	Dashboard del gerente
GET /asignacion/ejecutivo/{cod_ejec_bco}	Reporte del ejecutivo: clientes, mix A/B/C, gerente al que reporta	Reporte interno
GET /metricas/run/{run_id}	KPIs de una corrida: x/y, %A, %B, utilización media	Comité, área analítica
GET /metricas/historico	Evolución mensual de los KPIs para detectar drift	Power BI ejecutivo

La arquitectura incluye además una **capa de agentes IA sobre MCP (Model Context Protocol)**: un servidor MCP en Lambda expone los endpoints como herramientas, y cualquier asistente IA (Claude en Bedrock, copilots, agentes propios) las consume sin integraciones ad-hoc.



Componentes AWS y decisiones técnicas



AWS Lambda · job de modelado

Container image desde ECR con uv;
corre en < 1 s, sin servidores.



EventBridge + Step Functions

Trigger mensual y orquestación
extract → modelo → validators
con reintentos.



Amazon Redshift Serverless

Tabla de asignaciones particionada
por run_id; histórico replicado a S3.



API Gateway + Lambda (FastAPI)

REST con WAF, autenticación Cognito
y FastAPI sobre Mangum.



Cognito + IAM + KMS

OAuth2/SAML federado, least-
privilege por servicio y cifrado en
reposito.



CloudWatch + X-Ray + SNS

Logs, traceo distribuido y alertas si
métricas hacen drift > 15% MoM.



ECR + CodePipeline

Versiona imágenes con SemVer; build,
test y deploy automáticos al hacer
push.



QuickSight

Dashboards ejecutivos conectados
directo a Redshift, sin SQL para el
usuario.



Servidor MCP · Lambda

Expone endpoints como tools MCP
para cualquier asistente IA (Claude,
copilots).



Asistente del gerente

Amazon Lex + Chime SDK en
Teams/Slack/móvil que consulta el
MCP.



Explainer · Bedrock Agents

Genera la razón en lenguaje natural de
cada asignación (cumplimiento).



Copilot what-if · SageMaker

Notebook + tool MCP para
simulaciones de escenarios sin
escribir código.



Watchdog agent

EventBridge → Lambda → SNS con alerta proactiva si hay drift.

Gobernanza de agentes

Roles IAM por agente, logs cifrados y política de no-fabricación.

INSIGHT

El modelo en sí es lo más barato del sistema: corre en menos de 1 segundo. Lo que cuesta dinero y tiempo de implementación es la **infraestructura de servicio**: API, cache, autenticación, observabilidad y gobernanza. Por eso el bosquejo se concentra en separar las capas y dejar el cómputo desacoplado: cualquier mejora futura del modelo (cambiar pesos, agregar SA, escalar el problema) se publica reemplazando el job batch sin tocar la API ni los consumidores.

Conclusiones

1

La métrica obtenida coincide con el techo teórico

40.76% $\approx$ 40.8% predicho. Esto valida que el modelo es óptimo y que el techo no es artefacto del algoritmo.

2

Convergen porque no compiten por capacidad

Sobre-oferta (ratio 0.70). El MILP no encuentra ganancia porque no hay decisión real que tomar.

4

El verdadero entregable es el diagnóstico

El CSV se podría producir con regla determinista en 0.06 s. Lo valioso es el techo cuantificado *antes* de optimizar.

5

Frontera tenue entre optimización y datos

Aceptar que es proyecto de gobernanza, no de algoritmos, demuestra madurez analítica.

5

El análogo físico vale más allá de este problema

Aunque innecesaria para este caso concreto, pueden existir muchos problemas del banco donde los análogos físicos (spin glass, mean-field, transiciones de fase) permitan entender y explicar mejor el negocio.

7

La métrica oficial puede ser injusta

Reportar 40.76% sin contexto omite que el techo del problema está en 40.8%. Por eso este informe empieza por el techo.

Oportunidades de mejora

Oport.

Reconciliar huérfanos en ecas

Recupera los 633 ejecutivos que están en clientes pero no en ecas. Sin tocar algoritmo.

↑ Métrica: 40.8% → 53.4% (+12.6 puntos)

Oport.

Tabla maestra de productos

Vocabulario unificado entre oportunidades y encuesta. Hoy mitigado con mapeo manual.

↑ τ_c con error reducido del 50% al 10%

Oport.

Telemetría real de actividad

Reemplazar la encuesta auto-reportada con tiempos medidos directamente del CRM.

↑ Validez del modelo en producción

Oport.

Variables internas adicionales

Histórico de campañas, tasa de respuesta, ticket promedio, churn, todas desde el data warehouse.

↑ Mejor priorización dentro de A/B

Oport.

Variables externas (DataCrédito, DANE)

Buró, estrato, sector económico. APIs ya existentes. Solo si los pasos previos plateauean.

Bancolombia

Modelo de Capacidad · Asignación óptima cliente / gerente

Pipeline reproducible: `uv run python -m modelo_capacidad.run_all`

 github.com/jdrincone/modelo-capacidad

 Versión publicada: modelo-capacidad.netlify.app

Generado el 8 de mayo de 2026 · jdrincon@gmail.com